

1. INTRODUÇÃO

A análise de amostras celulares constitui uma etapa fundamental em diversas áreas da biologia, medicina e ciências da saúde. Por meio do exame microscópico de células, é possível identificar padrões morfológicos, detectar anomalias e subsidiar diagnósticos clínicos de alta relevância, como infecções, processos inflamatórios e neoplasias. Historicamente, essa análise tem sido realizada de forma manual por profissionais especializados, o que torna o processo passível de variações interpretativas e de elevado consumo de tempo.

Com o avanço das tecnologias de Inteligência Artificial (IA) e Visão Computacional, tornou-se possível automatizar tarefas complexas de reconhecimento de padrões visuais com alto grau de precisão. Algoritmos de aprendizado profundo (deep learning), baseados em redes neurais convolucionais, têm demonstrado resultados expressivos em tarefas de classificação e segmentação de imagens biomédicas, aproximando-se, em muitos contextos, do desempenho de especialistas humanos.

Nesse cenário, o presente trabalho propõe o desenvolvimento de um sistema inteligente e distribuído voltado à análise automatizada de amostras celulares. A solução integrará técnicas de aprendizado de máquina com processamento de imagens em tempo real, possibilitando a identificação, classificação, contabilização e rastreamento de células de forma ágil e confiável. A arquitetura do sistema contempla componentes desenvolvidos em Python — utilizando TensorFlow, Keras e OpenCV — e um portal web desacoplado construído com .NET e Entity Framework, comunicando-se via WebSocket por meio de uma API desenvolvida com FastAPI.

Além das funcionalidades de análise, o sistema permitirá que usuários enviem novos datasets ao portal, contribuindo para a expansão contínua da base de conhecimento da IA. Essa característica colaborativa favorece a escalabilidade do modelo ao longo do tempo, tornando a plataforma progressivamente mais robusta e abrangente.

1.1 Justificativa

A realização manual de análises celulares enfrenta desafios estruturais que comprometem a eficiência e a padronização dos processos laboratoriais. A subjetividade inerente à interpretação humana, a necessidade de profissionais altamente capacitados e o elevado tempo despendido em análises de grande volume são limitações reconhecidas na literatura científica.

Em contextos de alta demanda, como laboratórios clínicos e centros de pesquisa, essas restrições podem impactar diretamente a qualidade e agilidade dos resultados.

A automação inteligente desse processo por meio de redes neurais representa uma oportunidade significativa para elevar a confiabilidade diagnóstica e reduzir a carga cognitiva sobre os profissionais envolvidos. Sistemas baseados em IA têm demonstrado capacidade de manter desempenho consistente em análises repetitivas, minimizando erros decorrentes de fatores humanos como fadiga e variação de critérios interpretativos.

Do ponto de vista tecnológico, a maturidade atual das ferramentas de aprendizado de máquina, como TensorFlow e Keras, aliada à disponibilidade de frameworks para processamento de imagens como OpenCV, permite o desenvolvimento de soluções robustas com custo computacional acessível. A integração com tecnologias web modernas, como FastAPI e .NET, viabiliza a criação de sistemas escaláveis e de fácil acesso para diferentes perfis de usuários.

Outro aspecto relevante que justifica o presente projeto é o caráter colaborativo da plataforma proposta. Ao permitir o envio de novos datasets pelos usuários, o sistema incentiva a construção coletiva de conhecimento, aproximando-se do conceito de ciência aberta e democratizando o acesso a ferramentas avançadas de análise celular. Tal abordagem é especialmente relevante em países em desenvolvimento, onde o acesso a equipamentos e softwares especializados pode ser limitado.

Portanto, o desenvolvimento deste sistema justifica-se tanto pelo potencial impacto direto na qualidade dos processos laboratoriais quanto pela contribuição ao campo da inteligência artificial aplicada à saúde, área de crescente relevância científica e tecnológica.

1.2 Objetivos

1.2.1 Objetivo Geral

Desenvolver um sistema inteligente e distribuído capaz de analisar, identificar, classificar e rastrear amostras celulares em tempo real, integrando técnicas de Inteligência Artificial e Visão Computacional, e possibilitando a expansão colaborativa do conhecimento por meio do envio de novos datasets por usuários.

1.2.2 Objetivos Específicos

- Desenvolver uma rede neural para reconhecimento e classificação de padrões celulares, utilizando Python com TensorFlow e Keras;

- Implementar o processamento de imagens em tempo real utilizando a biblioteca OpenCV, possibilitando a detecção e o rastreamento de células em sequências de vídeo ou imagens microscópicas;
- Criar um serviço de transmissão de dados em tempo real via WebSocket, utilizando FastAPI, para comunicação entre o módulo de análise e a aplicação web;
- Desenvolver um portal web desacoplado para visualização das análises celulares em tempo real, utilizando tecnologias .NET e Entity Framework;
- Implementar um módulo para envio, armazenamento e gerenciamento de datasets, permitindo a expansão contínua e colaborativa da base de conhecimento da inteligência artificial.

2. REVISÃO DE LITERATURA

2.1 Análise Celular e Histologia

A histologia estuda os tecidos biológicos por meio de microscopia, sendo base fundamental da biologia e da medicina. A análise de células — forma, tamanho, organização e características nucleares — é essencial para o diagnóstico clínico (Ross & Pawlina, 2016). A interpretação das imagens exige treinamento especializado, o que torna a automação desse processo cada vez mais relevante (Kumar et al., 2021).

2.2 Inteligência Artificial e Aprendizado Profundo

A Inteligência Artificial abrange sistemas capazes de realizar tarefas que normalmente exigiriam inteligência humana, como reconhecimento de padrões e tomada de decisão (Russell & Norvig, 2020). No contexto de imagens, destaca-se o aprendizado profundo, que utiliza redes neurais de múltiplas camadas para extrair características diretamente dos dados (LeCun, Bengio & Hinton, 2015).

As Redes Neurais Convolucionais (CNNs) são a principal arquitetura para visão computacional, com modelos como ResNet e EfficientNet alcançando alto desempenho em tarefas médicas (He et al., 2016). Estudos indicam que redes profundas podem igualar ou superar patologistas humanos em tarefas específicas de análise histológica (Litjens et al., 2017).

2.3 Visão Computacional e Processamento de Imagens

A visão computacional desenvolve métodos para que computadores interpretem imagens digitais, incluindo classificação, detecção de objetos e segmentação (Szeliski, 2022). Técnicas clássicas como filtragem, morfologia e detecção de bordas são aplicadas para preparar imagens antes da análise por redes neurais (Gonzalez & Woods, 2018).

A biblioteca OpenCV é a principal referência para implementação de algoritmos de visão computacional em tempo real, com suporte a Python e C++ e compatibilidade com frameworks de deep learning (Bradski & Kaehler, 2008).

2.4 Frameworks de Aprendizado de Máquina: TensorFlow e Keras

TensorFlow é uma plataforma open-source para aprendizado de máquina desenvolvida pelo Google, com suporte a treinamento e inferência em CPUs, GPUs e TPUs (Abadi et al., 2016). Keras, integrada ao TensorFlow como API de alto nível, permite o desenvolvimento ágil de modelos complexos, equilibrando facilidade de uso e flexibilidade (Chollet, 2021).

2.5 Desenvolvimento de APIs e Comunicação em Tempo Real

FastAPI é um framework Python moderno para construção de APIs de alto desempenho, com suporte assíncrono e geração automática de documentação (Ramírez, 2019). O protocolo WebSocket permite comunicação bidirecional e persistente entre cliente e servidor com baixa latência, sendo amplamente utilizado em sistemas de monitoramento em tempo real (Fette & Melnikov, 2011).

2.6 Desenvolvimento Web com .NET e Entity Framework

O ASP.NET Core permite a construção de aplicações web e APIs RESTful com alto desempenho e suporte multiplataforma (Microsoft, 2023). O Entity Framework Core é o ORM padrão do ecossistema .NET, simplificando a camada de persistência por meio do mapeamento entre objetos C# e bancos de dados relacionais (Smith, 2019).

2.7 Arquiteturas de Sistemas Distribuídos e Desacoplamento

Sistemas distribuídos são compostos por múltiplos componentes que se comunicam em rede para atingir um objetivo comum. O desacoplamento entre componentes favorece a escalabilidade, a manutenibilidade e a substituíbilidade das partes do sistema (Tanenbaum & Van Steen, 2017).

2.8 Aprendizado Contínuo e Datasets Colaborativos

O aprendizado contínuo refere-se à capacidade de sistemas de IA de incorporar novos conhecimentos sem perder os anteriores — desafio conhecido como esquecimento catastrófico (Parisi et al., 2019). A coleta colaborativa de dados por usuários, alinhada ao conceito de crowdsourcing científico, tem demonstrado resultados positivos em projetos como o ImageNet e o CAMELYON Grand Challenge (Litjens et al., 2018).

Bibliografia

Murhekar, M. v., Bhatnagar, T., Thangaraj, J. W. V., Saravanakumar, V., Kumar, M. S., Selvaraju, S., Rade, K., Kumar, C. P. G., Sabarinathan, R., Turuk, A., Asthana, S., Balachandar, R., Bangar, S. D., Bansal, A. K., Chopra, V., Das, D., Deb, A. K., Devi, K. R., Dhikav, V., ... Vinod, A. (2021). SARS-CoV-2 seroprevalence among the general population and healthcare workers in India, December 2020–January 2021. *International Journal of Infectious Diseases*, 108, 145–155. <https://doi.org/10.1016/j.ijid.2021.05.040>

Murhekar, M. v., Bhatnagar, T., Thangaraj, J. W. V., Saravanakumar, V., Kumar, M. S., Selvaraju, S., Rade, K., Kumar, C. P. G., Sabarinathan, R., Turuk, A., Asthana, S., Balachandar, R., Bangar, S. D., Bansal, A. K., Chopra, V., Das, D., Deb, A. K., Devi, K. R., Dhikav, V., ... Vinod, A. (2021). SARS-CoV-2 seroprevalence among the general population and healthcare workers in India, December 2020–January 2021. *International Journal of Infectious Diseases*, 108, 145–155. <https://doi.org/10.1016/j.ijid.2021.05.040>

Lecun, Y., Bengio, Y., & Hinton, G. (2015). Deep learning. In *Nature* (Vol. 521, pp. 436–444). Nature Publishing Group. <https://doi.org/10.1038/nature14539>

Bejnordi, B. E., Veta, M., van Diest, P. J., van Ginneken, B., Karssemeijer, N., Litjens, G., van der Laak, J. A. W. M., Hermesen, M., Manson, Q. F., Balkenhol, M., Geessink, O., Stathonikos, N., van Dijk, M. C. R. F., Bult, P., Beca, F., Beck, A. H., Wang, D., Khosla, A., Gargeya, R., ... Venâncio, R. (2017). Diagnostic assessment of deep learning algorithms for detection of lymph node metastases in women with breast cancer. *JAMA - Journal of the American Medical Association*, 318, 2199–2210. <https://doi.org/10.1001/jama.2017.14585>